実験手順書（完全版）学校事故自由記述のLLM分類

Oct 25, 2026 · @熊田昌太郎

目的と研究課題

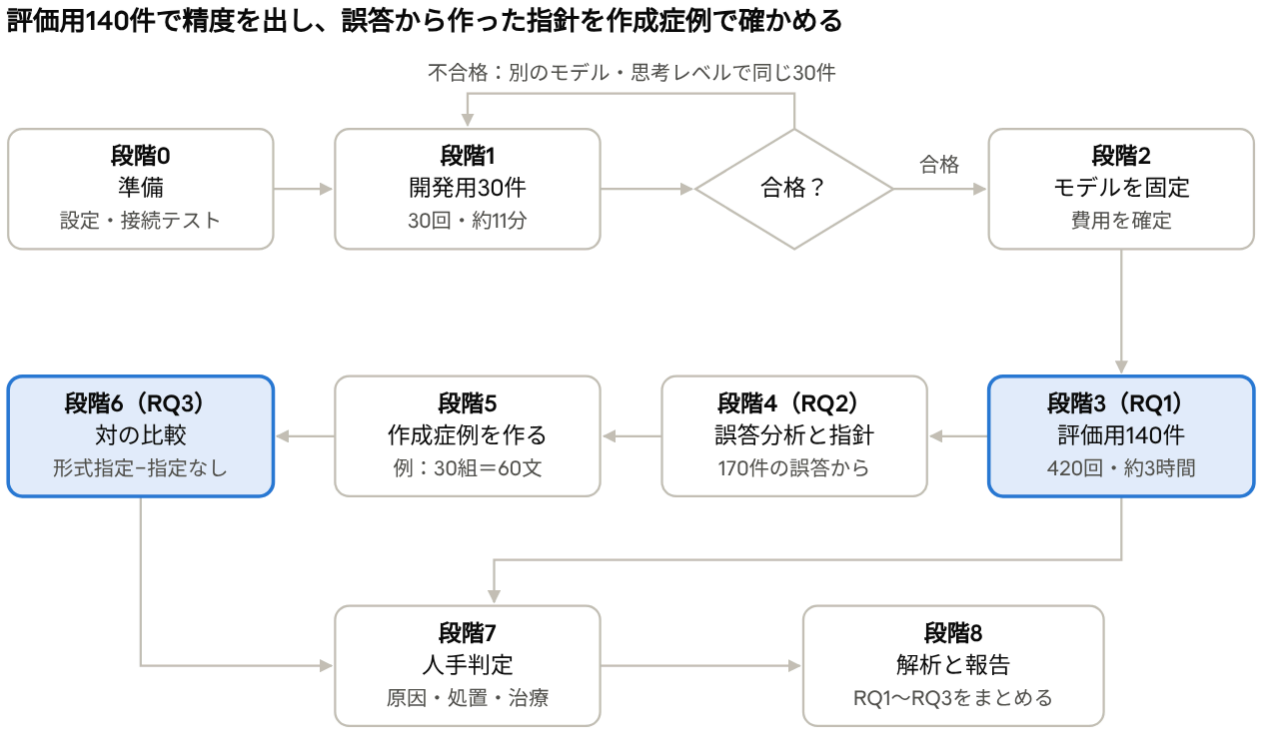
この実験では、歯牙欠損事例の自由記述をLLMで分類し、元の項目との一致率を測ります。さらに、誤りから作った「書き方の指針」で一致率が上がるかを確かめます。研究課題は次の3つです。

研究課題	答えるデータ	主な結果
RQ1 元の自由記述をAIはどれだけ正確に分類できるか	実データの評価用140件（31〜170件目）	項目ごとの一致率（95%CI）、記述から読める6項目の全体の正解率
RQ2 AIはどんな誤りをするか	実データ170件すべての誤答	誤りの種類A〜Gの件数と典型例
RQ3 指針どおりに書くと一致率は上がるか	作成症例（同じ設定を「指定なし」「形式指定」の2通りで書いた対）	1症例あたり正解割合の差（形式指定 − 指定なし）

- **データ**：JSC 学校等事故事例検索データベースの歯牙欠損見舞金事例（shiga_2026_1_30_.xlsx、170件）。令和3・4年度の給付。
- **AI**：gemini-3.8-flash（正式版）、思考レベル low、温度0、seed 42。指示は prompt-v3、後処理は rules-v2。
- **副次の目的**：治療・処置を要約し、医師が後から見てわかりやすくする。その正確さは人手判定で確かめる。

全体の流れ

実験は段階0〜8の順に進めます。主要な結果を出すのは、段階3（RQ1・評価用140件）と段階6（RQ3・作成症例の対の比較）の2か所です。



実験の流れ · 段階0〜8、合格判定1か所

開発用30件で合格したモデルを固定してから、評価用140件を流します。作成症例は、誤答から作った指針を固定してから書きます。呼び出し回数の合計は、作成症例30組の場合で約630回（開発用30＋評価用420＋作成症例180）です。

段階0 準備

本番はPCのChromeでWeb版（https://kuma428.github.io/jiko-llm-web/）を使います。Web版は1件終わるごとに結果をブラウザに保存します。ページを閉じたり再読み込みしたりしても、その実行を開いて「続きから再開」を押せば、残りだけを流せます。保存先はその端末のそのブラウザだけなので、本番は最初から最後まで同じPC・同じブラウザ・1つのタブで行います。

1. **APIキーを用意する**：田邊元先生のGoogle Cloudプロジェクト（有料枠）で作る。「予算とアラート」は1.5万円で設定してもらう。
2. **アプリを最新にする**：GitHub（jiko-llm-web）の index.html を最新版に上書きし、Web版を開いて再読み込みする。画面右上が prompt-v3 で、一括分類の画面に「件目から」があれば最新。
3. **設定画面**：接続先を Gemini にして、次の値を入れる。

設定	値
モデル	gemini-3.8-flash

設定	値
思考レベル	low
呼び出し間隔	15秒
温度・seed	0・42（既定のまま）

4. **接続テスト**：設定画面の「接続テスト」を押す。次に「新規登録」で1件だけ分類し、結果が返ることを確かめる。APIキーは「このブラウザに保存」にする（保存しないと、再読み込み後に再開できない）。
5. **PCの電源設定**：スリープを「なし」にする。評価用は約2.5〜3時間かかる。
6. **データの確認**：shiga_2026_1_30_.xlsx の元ファイルはそのまま保管し、書き換えない。並び順も変えない（開発用＝先頭30件、評価用＝31件目から、と並び順で分けるため）。

正解列の扱い（一括分類で自動に設定される）

項目	正解	備考
種別	照合しない	全件「歯牙欠損」で選択肢に無いため
学校種・学年・性別	元データの列	記述にほぼ書かれないため、誤りは主にA（書かれていない）になる
場合別1・2、発生場所1・2、通学方法、競技種目	元データの列	通学方法・競技種目の空欄は「該当なし」として照合
治療	記述から規則で作った参照値	段階7で人が確かめる
原因・処置	自動では照合しない	段階7の人手判定

段階1 開発用30件と段階2 モデルの固定

開発用30件で、gemini-3.8-flash が合格基準を満たすかを確かめます。満たしたら、モデル・思考レベル・指示を固定し、以後は変えません。

手順

1. 一括分類で shiga を読み込む。「1件目から」「30件だけ」、実行回数 1 にして開始する（30回、約11分）。
2. 終わったら結果Excelを保存する（結果はブラウザにも残るが、その端末だけなのでExcelで保管する）。
3. 「AIの出力のみで評価」の表で、合格基準を確かめる。

合格基準：① 30件すべて失敗0件で完了する。② 記述から読める6項目すべてで、一致率が下の「最多区分を当てた場合」を上回る。

項目	最多区分（開発用30件）	超えるべき一致率
場合別1	通学中 10件	33.3%
場合別2	体育的部活動 8件	26.7%
発生場所1	学校外 13件	43.3%
発生場所2	道路 10件	33.3%
通学方法	該当なし 20件	66.7%
競技種目	該当なし 17件	56.7%

合格した場合：gemini-3.8-flash・low・prompt-v3・rules-v2 で固定する。結果Excelの入力・出力・思考トークン数から、1回あたりの費用を計算し、田邊先生に確定した見積もりを報告する。

合格しなかった場合：同じ30件で、別のモデル（4 Argon または 3.5 Flash-Lite）か思考レベル medium を試し、一番よいものを選ぶ。選ぶのは開発用30件の結果だけで行い、評価用を流した後には変えない。指示を変える場合は prompt-v4 として記録し、開発用30件からやり直す。

注：開発用30件には「抜歯」の事例が1件も無い（歯科補綴26・記載なし3・その他1）。治療の抜歯の区分は、評価用140件で初めて確かめられる。

段階3 評価用140件

評価用140件の結果が、RQ1（実データでの精度）として報告する数字になります。段階2で固定した設定を変えずに流します。

1. 一括分類で shiga を読み込む。「31件目から」、件数は空欄（最後まで）、実行回数 3 にする。
2. 画面が「31〜170件目（140行）× 3回」になっていることを確かめて開始する（420回、約2.5〜3時間）。
3. 実行中はPCを閉じない。止まっても「失敗した分だけ再実行」で続きからやり直せる。ページを閉じてしまったら、同じブラウザでWeb版を開き、一括分類の一覧からその実行を開いて「続きから再開」を押す。タブは前に出しておく（裏に回ると遅くなることがある）。
4. 終わったら結果Excelを保存する。失敗が残った場合は、その件数と理由（「エラー」列）を記録する。

記録するもの

- 項目ごとの一致率、95%CI、最多区分を当てた場合、記載なし率（実行1回目、AIの出力のみ）
- 全体の正解率と全項目正解率（「記述から読める6項目」と「主要9項目」の両方）
- 実行回の間で答えが同じだった割合（3回すべて一致）
- 参考として「明記のみ」「規則で補完後」の一致率と、AIの推定数（うち正解）
- 実際の費用（Google Cloudの請求額）

評価用の結果を見てから、モデル・指示・後処理・正解列を変えてやり直すことはしません。やり直した場合は、その事実と理由を報告に書きます。

段階4 誤答分析と書き方の指針

実データ170件の誤答を種類ごとに数え、書き手が直せる誤り（A・D・F）から指針を作ります。指針を作ってもAIへの指示は変わらないので、評価用の誤答を使ってもRQ1の数字には影響しません。指針の効果は、別のデータ（作成症例）で確かめます。

1. 開発用30件と評価用140件の結果Excelから、「誤答一覧」「誤答の型（典型例）」シートを開く（実行1回目、AIの出力のみ）。
2. 記号A〜Gは辞書による自動の分け方なので、記述を読んで正しいか確かめる。直した場合は「修正後の記号」列を足して書き、元の記号は消さない。
3. 項目×記号の件数を表にする。件数の多いものから、指針の項目にする。
4. 指針の1項目ごとに、根拠になった誤答の件数と例（データ番号）を付ける。
5. 指針をテンプ6欄（誰が・いつ・どこで・何をしていて・何が原因で・どうなった）に割り当て、「指針第1版」として日付つきで保存する。作成症例を書き始めたら、指針は変えない。

記号	意味	指針での扱い
A	記述に正解を示す語が無い	「何を書くか」の指針にする
D	正解と別の区分の両方を示す語がある	「どう書くか」の指針にする
F	どちらを示す語も無い（AIが推定）	「何を書くか」の指針にする
B・C	書いてあるのにAIが誤った	指針には入れず、AIの限界として報告する
E	記述と元の分類が食い違う	指針には入れず、元データの問題として報告する。正解列は書き換えない
G	辞書に無い区分	記述を読んでA〜Fに振り分ける

指針の例（qwen3:14b・開発用30件の結果から）：誤り106件のうち51件がAで、内訳は性別が30件、学校種が21件でした。ここから『誰が』の欄には学校種・学年・性別を必ず書く、という指針ができます。本番ではGeminiの結果で作り直します。

段階5・6 作成症例の作成と対の比較

同じ架空の事故（正解カード）を「指定なし」と「形式指定（指針どおり）」の2通りで書き、AIの一致率を症例ごとに比べます。これがRQ3の主要解析です。

段階5 作成症例を作る

1. **正解カードを先に作る**：1枚＝架空の事故の事実一式（学校種・学年・性別・場合別1・2・発生場所1・2・通学方法・競技種目・治療・原因・処置）。区分が偏らないように、実データにある場面（通学中・部活動・体育・休憩時間など）を散らす。抜歯の事例も入れる。
2. **文を書く**：作成症例テンプレ（一括分類の画面から保存）に、1行＝1つの文で書く。同じカードから「指定なし」と「形式指定」の2行を作り、同じ症例ID（S001など）を付ける。正解列にはカードの値をそのまま書く。
   - 指定なし：カードを見て、ふだん報告書を書くつもりで自由に書く。カードの事実をどこまで書くかは書き手に任せる。
   - 形式指定：指針第1版どおりにテンプ6欄を埋める。
3. **書き手の割り当て**：同じ人が同じカードの両方を書くと、指針を知った後の「指定なし」に指針の内容が混ざる。できれば2人で分け、カードの前半は自分が指定なし・ペアが形式指定、後半はその逆にする。1人で書く場合は、先に全カードの指定なしを書き終えてから形式指定を書く。

4. **AI生成の症例を使う場合**：「作成」列を「AI生成」にする。分類に使うGeminiで文を作ると有利になりうるので、別のモデルで作る。主要解析は手作りの症例だけで行い、AI生成は別に報告する。
5. **書き終えたら固定する**：AIに流した後で、結果を見て文や正解列を直さない。

段階6 作成症例を分類して比べる

1. 一括分類で作成症例のExcelを読み込む。正解列は同じ名前の列に自動で対応する（治療もカードの値と照合する）。
2. 「1件目から」、件数は空欄、実行回数 3。「版」「症例ID」列があるので、対の比較が自動で計算される。
3. 主要解析「形式指定 − 指定なし」の表を記録する（実行1回目、AIの出力のみ、主要9項目）。

作成症例の数	文の数	呼び出し回数（3回）	所要時間の目安	検出できる差（効果量 d）
30組	60	180回	約1時間半	約0.53
90組	180	540回	約4時間	約0.30

検出できる差は、両側検定・有意水準5%・検出力80%での対応のあるt検定の目安です。

段階7 人手判定

自動で照合できない「原因・処置」と、規則で作った「治療の参照値」を、人が確かめます。判定は2人が別々に行い、後で突き合わせます。

原因・処置の判定

1. 各一括分類の画面で「人手判定用Excel（原因・処置）」を保存する。判定の順番は並べ替え済みで、「判定」シートには版が出ない。
2. 「対応表（判定者に見せない）」シートを削除したコピーを、判定者に渡す。元のファイルは自分で保管する。
3. 判定者は判定列を次の基準で選ぶ。2人の判定が違ったものは話し合いで決める。
4. 「合っている」の割合（95%CI）を、項目ごと・版ごとに出す。2人の一致率とκ係数も出す。判定結果を集計する機能はアプリにまだ無いので、Excelで集計するか、集計機能を追加する。

判定	基準（案）
合っている	記述にある原因（処置）を表している。言い換えは可。記述に無いときに「記載なし」と答えた場合も含む

判定	基準（案）
違う	記述にあるのに「記載なし」、または別の内容（例：原因と結果の取り違え、処置と治療の取り違え）
作り話	記述に無い内容を足している

作成症例では、記述だけでなく正解カードの原因・処置とも比べられます。ただし形式指定の文は【誰が】などの見出しで版が分かるため、判定者から版を完全には隠せません（限界として書く）。

治療の参照値の確認（実データ170件）

1. 結果Excelから「データ番号」「記述」「参照値（規則）_治療」の3列だけを別のシートに写す。AIの答えの列は見ない。
2. 記述を読んで、参照値が正しいかを判定する（歯科の知識がある人が望ましい）。
3. 参照値と人の判定の一致率を報告する。人の判定を正解として、結果Excelの「AI_治療」列と比べ、治療の一致率を計算し直す（AIに流し直す必要はない）。

段階8 解析と報告する指標

主要な結果は、RQ1の「記述から読める6項目の一致率」と、RQ3の「形式指定 − 指定なし」の差の2つです。それ以外は副次の結果として報告します。どの数字も、研究のLLM精度としては「AIの出力のみ」・実行1回目の値を使います。

区分	指標	データ	方法
主要（RQ1）	項目ごとの一致率	評価用140件	95%CIはWilson法。最多区分を全件に当てた場合と並べる
主要（RQ3）	1症例あたり正解割合の差（形式指定 − 指定なし）	作成症例（手作り）	平均差とt分布の95%CI、Wilcoxon符号順位検定。対象は主要9項目
副次	項目ごとの差	作成症例	McNemar正確検定＋Holm法で多重比較を補正
副次	全体の正解率・全項目正解率	評価用140件、作成症例	6項目と主要9項目の両方、95%CI
副次	誤りの種類A〜Gの件数	実データ170件	人が確かめた記号で集計
副次	実行回の間で答えが同じだった割合	評価用140件、作成症例	3回すべて同じ答えだった割合

区分	指標	データ	方法
副次	治療の一致率	実データ、作成症例	実データは人が確かめた参照値と比べる
副次	原因・処置の「合っている」の割合	人手判定	割合と95%CI、2人のκ係数
参考	明記のみ・規則で補完後の一致率、AIの推定数	評価用140件	入力支援としての使いやすさの参考

解釈の注意

- 差が有意にならなかった場合は「差がない」ではなく、「この件数では検出できなかった」と書く。
- 学校種・学年・性別は、実データでは記述にほぼ書かれていない。一致率が低いのはAIの誤りではなく、書かれていないため。
- 形式指定の効果には、「書き方の違い」と「書かれる情報の量の違い」の両方が含まれる。この実験で測っているのは、指針全体の効果。

守るルールと限界

結果を歪めないためのルール

- モデル・思考レベル・指示・後処理は、開発用30件だけで決める。評価用や作成症例の結果を見て変えない。
- 正解（元データの列・正解カード）を、AIの答えに合わせて書き換えない。元データがおかしいと思ったものは、誤りの種類Eとして報告する。
- 版の違う結果を合算しない。結果Excelの全行に、モデル・指示の版・温度・seed・実行日時が残る。
- 指針第1版は、作成症例を書き始める前に固定する。
- 人手判定のシートには版を入れない。治療の参照値は、AIの答えを見ずに確かめる。
- やり直しや例外は、日付・理由・影響を記録して報告する。

データとAPIキーの扱い

- AIに入れるのは、公開データと架空の症例だけ。データの送り先はGemini APIだけ。
- APIキーはアプリの設定画面だけに入れ、ファイル・Excel・メールには書かない。研究が終わったら無効にする。
- 公開リポジトリ（jiko-llm-web）に、Excelや結果ファイルを置かない。

限界（報告に書くこと）

- 実データは1つの給付（歯牙欠損見舞金）の170件だけで、令和3・4年度に限られる。他の事故の種類にそのまま当てはまるとは言えない。
- 実データの正解は、元の担当者が付けた分類で、それ自体に誤りがありうる。
- 治療の正解は規則で作った参照値で、人の確認が前提。「その他（再植など）」は実データに約1件しかなく、評価できない。
- 作成症例は架空で、実際の報告者の書き方とは違う可能性がある。
- Geminiは温度0・seed固定でも答えが揺れることがある（実行回の間の一致率で示す）。モデルの更新で結果が変わりうるので、実行日を報告する。
- 形式指定の文は見出しで版が分かるため、人手判定を完全に盲検化できない。

始める前に決めることとチェックリスト

次の4つは、まだ決まっていません。推奨案でよければ、そのまま進められます。

決めること	推奨案	理由	いつまでに
負傷・病名・時間を項目に足すか	足さない	足すと prompt-v4 になり、実データに正解列も無い	段階1の前
作成症例の数	手作り30組＋できればAI生成（別に報告）	30組で中程度の差（d≈0.53）を検出できる。計画書の90設定にするなら計画書をそのまま使う	段階5の前
作成症例の書き手	自分とペアの2人で、版を入れ替えて分担	指針を知った後の指定なしに、指針の内容が混ざるのを防ぐ	段階5の前
人手判定の判定者	2人（うち1人は歯科の知識がある人）	一致度（κ）を出せ、治療の参照値も確かめられる	段階7の前

チェックリスト

- [ ] 田邊先生から有料枠のAPIキー（またはプロジェクトへの追加）を受け取る
- [ ] Web版を最新にし、prompt-v3 であること、設定値、接続テスト、1件の試し分類を確かめる
- [ ] 上の4つを決める
- [ ] 段階1：開発用30件を流し、合格基準を確かめる
- [ ] 段階2：モデルを固定し、費用の見積もりを確定して報告する
- [ ] 段階3：評価用140件を3回流す
- [ ] 段階4：誤答を確かめ、指針第1版を固定する
- [ ] 段階5：正解カードと作成症例を作る

- [ ] 段階6：作成症例を3回流し、対の比較を記録する
- [ ] 段階7：原因・処置の人手判定と、治療の参照値の確認をする
- [ ] 段階8：指標をまとめ、限界とあわせて報告する